

hw3

Pablo, Román, Sofia

25/2/2020

```
##
## Ejercicios Pablo:
```

```
## [1] 5 2 9
```

```
##
## Ejercicios Roman:
```

```
## [1] 2 8 3
```

```
##
## Ejercicios Sofia:
```

```
## [1] 4 6 1
```

Ejercicio 2

Obtenemos la matriz muestral de varianzas y covarianzas, luego obtenemos los componentes principales muestral.

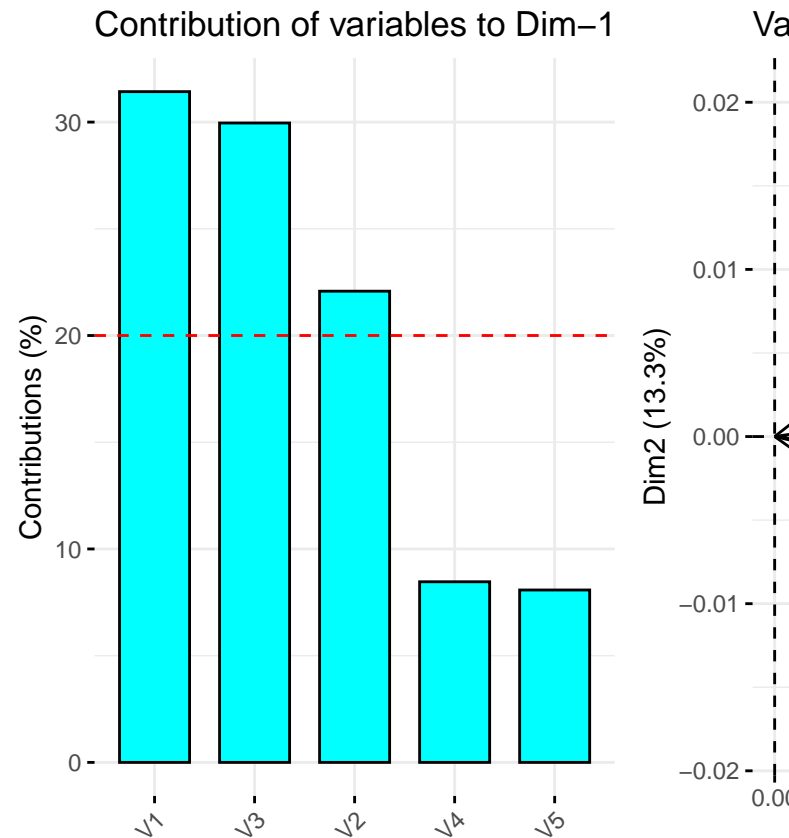
```
## La matriz de varianzas y covarianzas es:
```

	V1	V2	V3	V4	V5
V1	0.0016299	0.0008167	0.0008101	0.0004422	0.0005140
V2	0.0008167	0.0012294	0.0008276	0.0003869	0.0003109
V3	0.0008101	0.0008276	0.0015561	0.0004873	0.0004625
V4	0.0004422	0.0003869	0.0004873	0.0008023	0.0004085
V5	0.0005140	0.0003109	0.0004625	0.0004085	0.0007587

```
##
##
## Los componentes principales son:
```

```
##
## Loadings:
##   Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## V1  0.561  0.739  0.126  0.284  0.208
## V2  0.470           0.468 -0.688 -0.281
## V3  0.547 -0.654  0.114  0.500
## V4  0.291 -0.113 -0.610 -0.438  0.582
## V5  0.284           -0.617           -0.728
##
```

```
##          Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## SS loadings      1.0   1.0   1.0   1.0   1.0
## Proportion Var    0.2   0.2   0.2   0.2   0.2
## Cumulative Var    0.2   0.4   0.6   0.8   1.0
```



Veamos a detalle los componentes principales de los datos

Vemos que por un “análisis de codo”, las primeras **tres componentes principales** son las que contiene la mayor variabilidad. Veamos las comunalidades de las CP para encontrar una interpretación.

```
##
## Loadings:
##   Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## V1  0.561  0.739  0.126  0.284  0.208
## V2  0.470         0.468 -0.688 -0.281
## V3  0.547 -0.654  0.114  0.500
## V4  0.291 -0.113 -0.610 -0.438  0.582
## V5  0.284         -0.617         -0.728
##
##          Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## SS loadings      1.0   1.0   1.0   1.0   1.0
## Proportion Var    0.2   0.2   0.2   0.2   0.2
## Cumulative Var    0.2   0.4   0.6   0.8   1.0
```

Podemos ver que la primer componente es una ponderación de todas las acciones de la NYSE, mientras que la segunda componente distingue 3 grupos: La pprimera acción, las acciones 2 y 5 pero por último las acciones 3 y 4.

Sabemos por el *teorema de Anderson* que $\hat{\lambda} \sim \mathcal{N}(\lambda, 2\lambda^2/n)$, si $n \rightarrow \infty$. Por lo que podemos construir un intervalo de confianza bonferronizado (ya que por teorema $\lambda_i \perp \lambda_j \quad \forall i \neq j$.)

$$\lambda_i \in \frac{\hat{\lambda}_i}{1 \pm z_{\alpha/2m} \sqrt{2/n}}.$$

Por lo que tendremos un conjunto de intervalos de confianza al nivel del 90% para $\lambda_{1,2,3}$ dados por

1. 0.0458595, 0.0853459
2. 0.0215263, 0.040061
3. 0.0207552, 0.038626

Es importante ver que podemos **reducir la dimensión** de los datos en *3 componentes principales*, ya que en estas tres primeras componentes obtenemos el 85% de la variabilidad de los datos.

FALTA REPLICAR

Ejercicio 3

3a. Comparar estimaciones

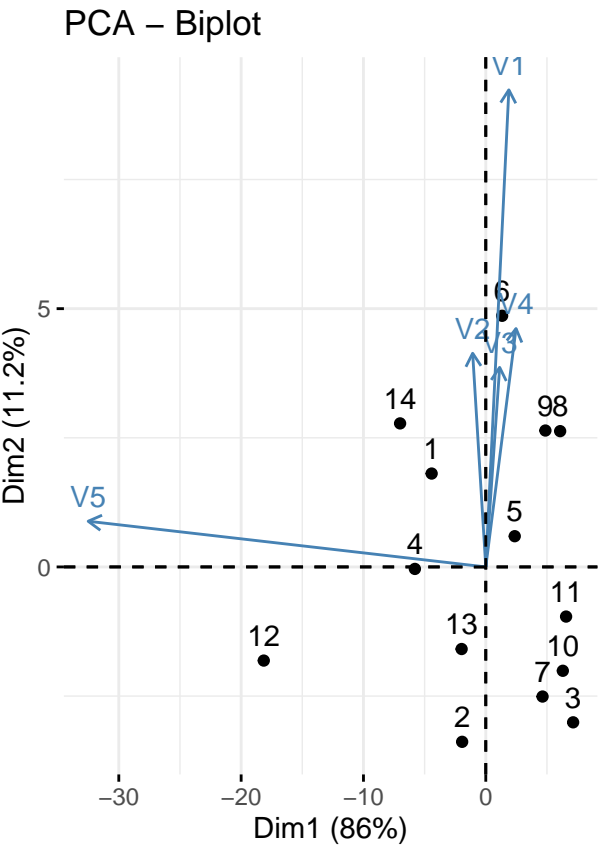



Veamos:

- El *error relativo para los scores* de las CP's, calculado por la $\|\cdot\|_\infty$ es: 2.8311423
- El vector con los errores relativos para λ 's estimadas es

	lambda
Comp.1	-1.7117792
Comp.2	-0.9300589
Comp.3	-0.9090022
Comp.4	-0.0005601
Comp.5	-0.0002891

Se puede concluir que el cambio de escala SÍ afecta la estimación de los componentes principales, y por mucho.

3b. Interpretación



```
##
## Loadings:
##   Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## V1  0.781          0.542  0.302
## V2  0.306  0.764 -0.162 -0.545
## V3  0.334          -0.937
## V4  0.426 -0.579  0.220 -0.636  0.172
## V5          0.262  0.962
##
##           Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## SS loadings      1.0   1.0   1.0   1.0   1.0
## Proportion Var    0.2   0.2   0.2   0.2   0.2
## Cumulative Var    0.2   0.4   0.6   0.8   1.0

##
## Loadings:
##   Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## V1      0.782          0.541  0.302
## V2      0.350  0.764 -0.540
## V3      0.327 -0.101          -0.938
## V4      0.391 -0.632 -0.642  0.172
## V5 -0.994
##
##           Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## SS loadings      1.0   1.0   1.0   1.0   1.0
## Proportion Var    0.2   0.2   0.2   0.2   0.2
## Cumulative Var    0.2   0.4   0.6   0.8   1.0
```

Para el caso de los datos originales, Y_1 es una ponderación de las 5 variables, dándole mayor peso a la primera variable. La segunda CP es una distinción entre la segunda variable y quinta variable contra la cuarta.

En el caso de los datos modificados, Y_1' se inclina *totalmente* hacia la última variable. Mientras que la segunda componente es un ponderaje de las primeras cuatro variables originales, se observa con mayor claridad en el *biplot*.

3c. Describir efectos

Vemos que el cambio de escala distorciona por completo los componentes principales y por ende su interpretación. Es recomendable en este caso usar R , o lo que es lo mismo, *estandarizar* los datos (studentizarlos).